



PROJETO FINAL - ORQUESTRAÇÃO DE WORKFLOW

1. Contexto

Ao longo desta disciplina você estudou e praticou as principais ferramentas de orquestração de workflows modernas: **Apache Airflow**, **Prefect** (local e distribuído) e **MLflow**. O trabalho final é a oportunidade de aplicar esses conhecimentos em um projeto próprio, de tema livre, demonstrando domínio técnico e capacidade de tomar decisões de arquitetura.

O projeto deve representar um pipeline de dados ou de Machine Learning real — não um exemplo didático mínimo, mas algo que você pudesse apresentar como referência de trabalho em um contexto profissional.

2. Formação das Equipes

- O trabalho pode ser realizado **individualmente ou em grupos de até 3 membros**.
 - A complexidade e o escopo esperados do projeto são **proporcionais ao tamanho da equipe**.
-

3. Regras de Uso das Ferramentas

- O projeto deve utilizar **pelo menos um orquestrador** estudado na disciplina: Apache Airflow ou Prefect.
 - O uso do **MLflow** é **opcional**, mas se for utilizado, **obrigatoriamente deve haver um orquestrador** integrando o pipeline — MLflow sozinho, sem orquestração, não é aceito.
 - O pipeline deve estar **dockerizado** e funcionar a partir de comandos docker (ex: `docker compose up`).
-



4. Sugestões de Tema

Os temas abaixo são sugestões — o grupo pode propor um tema próprio desde que envolva orquestração de pipeline. Em caso de dúvida sobre a adequação do tema, consulte o professor antes de iniciar.

4.1 CDC — Change Data Capture

Implementar um pipeline que detecta e captura mudanças incrementais em uma fonte de dados (banco relacional, arquivo, API) e as propaga para uma camada analítica. O desafio central é garantir que apenas os registros novos ou alterados desde a última execução sejam processados — sem reprocessar tudo do zero a cada run.

4.2 Arquitetura Medalhão (Bronze → Silver → Gold)

Construir um pipeline em camadas inspirado na arquitetura Medallion: a camada Bronze ingere dados brutos da fonte; a Silver aplica limpeza, tipagem e deduplicação; a Gold agrega e calcula as métricas finais prontas para consumo analítico. O orquestrador gerencia as dependências entre as camadas e garante idempotência em cada etapa.

4.3 Pipeline de ML Completo

Pipeline que percorre o ciclo completo de Machine Learning com orquestração: ingestão de dados → feature engineering → treinamento de múltiplos modelos → rastreamento de experimentos com MLflow → registro do melhor modelo no Model Registry → serving. O orquestrador (Airflow ou Prefect) coordena as etapas; o MLflow rastreia e versiona os modelos.

4.4 Monitoramento de Modelo em Produção

Pipeline que, após o deploy de um modelo, monitora continuamente a qualidade das predições: detecta data drift (mudança na distribuição dos dados de entrada) e concept drift (degradação da performance do modelo), loga alertas e métricas no MLflow, e pode acionar re-treinamento automático quando os limites configurados são violados.

4.5 Pipeline Financeiro

Pipeline de dados que consome cotações de ativos financeiros (ações, criptomoedas, índices) de uma API pública, calcula indicadores técnicos (médias móveis, RSI, Bollinger Bands, etc.), persiste o histórico em banco de dados e dispara alertas quando condições pré-definidas são atingidas. O orquestrador garante execução periódica, resiliência a falhas de API e idempotência nas gravações.

4.6 Pipeline de NLP

Pipeline que coleta textos de uma fonte (RSS, API de notícias, redes sociais, scraping), aplica pré-processamento (tokenização, limpeza, normalização), executa classificação ou análise de sentimento com um modelo pré-treinado ou fine-tuned, e persiste os resultados. Se usado com MLflow, o pipeline rastreia experimentos de fine-tuning e versiona os modelos utilizados.



5. Requisitos Mínimos do Pipeline

Independentemente do tema escolhido, o pipeline deve demonstrar:

- **Agendamento ou trigger** — o pipeline roda de forma automatizada (cron, evento, intervalo).
- **Resiliência** — tratamento de falhas com retry e/ou callbacks de ciclo de vida.
- **Idempotência** — re-executar o pipeline não gera duplicidade de dados.
- **Modularidade** — o código está organizado em tarefas/funções independentes e legíveis.
- **Persistência** — os resultados são gravados em algum destino (banco de dados, arquivo, registry).
- **Observabilidade** — é possível acompanhar o estado das execuções (UI do Airflow/Prefect ou logs do MLflow).

6. Modo de Entrega

 Todos os três itens de entrega são obrigatórios. A ausência de qualquer um implica desconto ou invalidação do critério correspondente.

6.1 Repositório GitLab / GitHub

- Disponibilizar o projeto em repositório **público** (GitLab, GitHub ou equivalente).
 - Repositórios Privado incluir meu usuário **reinaldocm-prof**
- O repositório deve conter **todo o código** necessário para executar o pipeline.
- Liberar acesso de visualização ao professor.
- **Postar o link do repositório na Plataforma.**

6.2 Documentação

A documentação pode ser entregue em qualquer um dos formatos abaixo:

- **README .md** no próprio repositório, **ou**
- Documento PDF, **ou**
- Apresentação de slides (PPT, Google Slides, etc.)

A DOCUMENTAÇÃO DEVE ESTAR INCLUÍDA NO REPOSITÓRIO

Conteúdo mínimo obrigatório:



- Descrição do problema/contexto que o pipeline resolve.
- Arquitetura da solução (diagrama ou descrição das camadas/etapas).
- Ferramentas utilizadas e justificativa das escolhas.
- Instruções de execução — como subir o projeto do zero.
- Decisões técnicas relevantes (ex: por que Airflow e não Prefect, por que essa estratégia de idempotência, etc.).

6.3 Pitch em Vídeo

- Gravação de **5 a 10 minutos** apresentando o projeto.
- O vídeo deve conter;
 - o problema que o pipeline resolve,
 - a arquitetura escolhida,
 - uma **demonstração do pipeline rodando** (pode ser gravação de tela),
 - e as principais decisões técnicas.
- O vídeo pode ser entregue como link (YouTube não listado, Google Drive, etc.).
 - Instruções de acesso ao mesmo devem estar disponível na documentação do projeto.

7. Critérios de Avaliação

Total: 50 pontos

Critério	Pontos	O que será avaliado
Pipeline funcionando	30 pts	O pipeline executa corretamente a partir do repositório; os requisitos mínimos estão presentes; o projeto está dockerizado
Apresentação (Pitch)	10 pts	Clareza na comunicação do problema e da solução; demonstração funcional do pipeline; domínio técnico demonstrado nas escolhas de arquitetura.
Documentação	10 pts	Cobertura do conteúdo mínimo obrigatório; clareza das instruções de execução; qualidade da descrição arquitetural.
TOTAL	50 pts	Todos os critérios são obrigatórios.

⚠ Todos os três critérios são obrigatórios. Um projeto sem documentação ou sem vídeo terá os pontos do critério correspondente zerados, independentemente da qualidade do pipeline.



8. Dicas para um Projeto de Destaque

- **Prefira profundidade a abrangência:** um pipeline simples bem feito, com idempotência real, resiliência testada e documentação clara vale mais que um pipeline complexo que não roda.
- **O README é o cartão de visitas:** quem abre o repositório de um projeto profissional espera conseguir rodar com `docker compose up` e entender a arquitetura em 5 minutos.
- **No pitch, mostre rodando:** uma demonstração ao vivo (gravada) do pipeline executando vale mais que qualquer slide de arquitetura.
- **Documente as decisões, não só o código:** "escolhi Prefect porque o pipeline é event-driven e não precisamos de scheduler" demonstra mais domínio que listar as ferramentas usadas.